

Índice

1. f.d.p. Gaussiana	2
1.1. Estimación con <i>hist</i> , <i>mean</i> y <i>std</i>	2
1.2. Valores de μ y σ^2 teóricas con estimadas	4
1.3. Estimaciones de μ_x - Histograma	4
1.4. Error en la estimación de μ_x - Ejemplo	5
2. Variables aleatorias conjuntamente gaussianas	7
3. Proceso de Poisson	9

1. f.d.p. Gaussiana

Para generar una f.d.p gaussiana X con media μ_x y varianza σ_x^2 , se utilizarán dos variables aleatorias U_1 y U_2 con distribución uniforme en $(0,1)$.

Partiendo de dos variables aleatorias R y Θ , la función de distribución de R :

$$F_R(r) = 1 - e^{-\frac{r^2}{2}} \quad 0 < r < \infty$$

Igualando a U_1 se puede despejar:

$$F_R(r) = U_1 \implies R = \sqrt{-2 \cdot \ln(U_1)}$$

La variable Θ tiene distribución uniforme:

$$F_\Theta(\theta) = \frac{\theta}{2\pi} \quad 0 < \theta < 2\pi$$

Igualando a U_2 se despeja:

$$F_\Theta(\theta) = U_2 \implies \Theta = 2\pi U_2$$

Se tiene entonces que:

$$Y = R \cdot \cos(\Theta) \implies Y = \sqrt{-2 \cdot \ln(U_1)} \cdot \cos(2\pi U_2)$$

Por lo que se consigue generar una variable aleatoria $Y \sim N(0, 1)$. Para obtener la variable aleatoria X con media y varianza personalizadas, se utiliza la transformación lineal:

$$X = \sigma_x \cdot Y + \mu_x$$

Donde efectivamente:

$$E(X) = \sigma_x \cdot \underbrace{E(Y)}_{=0} + \mu_x = \mu_x \quad \text{y} \quad \text{Var}(X) = \sigma_x^2 \cdot \underbrace{\text{Var}(Y)}_{=1} = \sigma_x^2$$

1.1. Estimación con *hist*, *mean* y *std*

Se realizó la simulación utilizando vectores de 1000, 5000 y 50000 elementos, que permiten visualizar en forma clara la diferencia entre los histogramas y las curvas teóricas para cada caso, mostrando una corrida a continuación. En los histogramas se utilizaron 100 barras.

Los parámetros utilizados son $\mu_x = 3$ y $\sigma_x^2 = 1$.

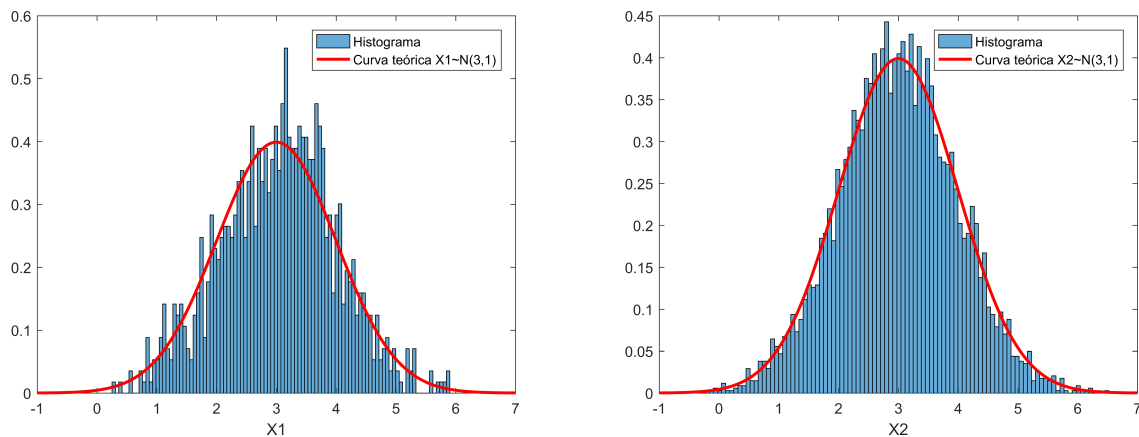


Figura 1: Comparación para vectores X_1 de 1000 elementos e X_2 de 5000 elementos




Figura 2: Comparación para vector X_3 de 50000 elementos

Utilizando un número fijo de barras adecuado, se consigue el ajuste mostrado en las gráficas anteriores. Para mayor cantidad de elementos, el histograma tiende a parecerse más a la curva de la gaussiana teórica.

El código de MatLab utilizado para la simulación se muestra a continuación.

```

1 %% Valores de media y varianza personalizados
2 mu_x = 3;
3 var_x = 1;
4
5 b = mu_x;
6 a = sqrt(var_x);
7
8 %% Item A
9 % Generacion de variables aleatorias uniformes en [0,1]
10 x1 = rand(1000,1);
11 x2 = rand(1000,1);
12 x3 = rand(5000,1);
13 x4 = rand(5000,1);
14 x5 = rand(50000,1);
15 x6 = rand(50000,1);
16
17 % Generacion de variables aleatorias gaussianas a partir de dos uniformes
18 y1 = a.*(sqrt(-2.*log(x1)).*cos(2.*pi.*x2)) + b;
19 y2 = a.*(sqrt(-2.*log(x3)).*cos(2.*pi.*x4)) + b;
20 y3 = a.*(sqrt(-2.*log(x5)).*cos(2.*pi.*x6)) + b;
21
22 % Curva teorica de comparacion
23 xi = (-4*a+b):0.001:(4*a+b);
24 z = normpdf(xi,mu_x,sqrt(var_x));
25
26 bars = 100; %Numero de barras
27
28 % Histogramas normalizados
29 figure;
30 histogram(y1,bars,'Normalization','pdf');
31 hold on;
32 plot(xi,z,'red','linewidth',2);
33 xlabel('X1');
34 legend('Histograma','Curva teorica X1-N(3,1)');
35 %print('X1_1000','-dpng','-r600');
36
37 figure;
38 histogram(y2,bars,'Normalization','pdf');
39 hold on;
40 plot(xi,z,'red','linewidth',2);
41 xlabel('X2');
42 legend('Histograma','Curva teorica X2-N(3,1)');
43 %print('X2_5000','-dpng','-r600');
44
45 figure;
46 histogram(y3,bars,'Normalization','pdf');
47 hold on;
48 plot(xi,z,'red','linewidth',2);
49 xlabel('X3');
50 legend('Histograma','Curva teorica X3-N(3,1)');

```

```

51 %print('X3_50000','-dpng','-r600');
52
53 mu_y = [mean(y1) mean(y2) mean(y3)];
54 var_y = [var(y1) var(y2) var(y3)];
55
56 %% Item B
57 % Calculo la diferencia en valor absoluto para comparar
58 comp_mu_y = [abs(mu_y(1) - mu_x) abs(mu_y(2) - mu_x) abs(mu_y(3) - mu_x)];
59 comp_var_y = [abs(var_y(1) - var_x) abs(var_y(2) - var_x) abs(var_y(3) - var_x)];

```

Listing 1: Código de implementación

1.2. Valores de μ y σ^2 teóricas con estimadas

De los vectores anteriores se estima la media y la varianza para cada caso, comparando con los teóricos en el siguiente cuadro.

Elementos	μ_x			σ_x^2		
	Teórico	Estimado	$\Delta\mu_x$	Teórico	Estimado	$\Delta\sigma_x^2$
1000	3	3.0402	0.0402	1	0.9348	0.0652
5000	3	2.9882	0.0118	1	0.9577	0.0423
50000	3	3.0006	0.0006	1	0.9984	0.0016

Cuadro 1: Valores estimados y teóricos

Dado que el número de elementos es bastante grande en los casos analizados, los valores estimados caen siempre muy cerca de los teóricos.

1.3. Estimaciones de μ_x - Histograma

Para este caso, se realizan 10000 estimaciones en distribuciones con 10000 elementos cada una. El código de MatLab utilizado para la simulación es el siguiente.

```

1 %% Valores de media y varianza personalizados
2 mu_x = 3;
3 var_x = 1;
4
5 b = mu_x;
6 a = sqrt(var_x);
7
8 %% Item D
9 % Se hace 10000 veces para ver la distribucion de las medias en conjunto
10 mu_x_dist = zeros(10000,1);
11 for i=1:10000
12     x1d = rand(10000,1);
13     x2d = rand(10000,1);
14     xd = a.*(sqrt(-2.*log(x1d)).*cos(2.*pi.*x2d)) + b;
15     mu_x_dist(i) = mean(xd);
16 end
17 figure;
18 mean(mu_x_dist);
19 std(mu_x_dist);
20 histogram(mu_x_dist,bars,'Normalization','pdf');
21 xlabel('Medias de X');
22 %print('MediasX','-dpng','-r600');

```

Listing 2: Código de implementación

Realizando un histograma de los valores obtenidos, se tiene:




Figura 3: Histograma de las medias estimadas, con resultante $\mu = 3,0001 - \sigma = 0,01$

Si llamamos a la media estimada m_X , se la define en este caso como:

$$m_X = \frac{1}{N} \cdot \sum_{i=1}^N \mu_{X_i} \quad \text{Con } N = 10000$$

Como la distribución normal es reproductiva, la suma de N variables aleatorias con dicha distribución resulta también normal. Esto último también puede verse desde el Teorema Central del Límite, dado que el valor de N utilizado es suficientemente grande. Para el caso en cuestión, los valores teóricos de μ y σ son:

$$E(m_X) = \mu = \frac{1}{N} \cdot \underbrace{\sum_{i=1}^N E(\mu_{X_i})}_{\text{Por linealidad}} = \frac{1}{N} \cdot \sum_{i=1}^N \mu_x = \mu_x \Rightarrow \mu = 3$$

$$\sigma^2(m_X) = \sigma^2 = \frac{1}{N^2} \cdot \underbrace{\sum_{i=1}^N \sigma^2(\mu_{X_i})}_{\text{Por independencia}} = \frac{1}{N^2} \cdot \sum_{i=1}^N \sigma_x^2 = \frac{\sigma_x^2}{N} \Rightarrow \sigma = 0,0001$$

De donde se observa que los valores estimados sobre la media del vector graficado en el histograma resultan muy cercanos a los teóricos.

1.4. Error en la estimación de μ_x - Ejemplo

Se toma ahora un caso particular, donde la cantidad de elementos es desconocida, y se busca que la probabilidad de que el valor estimado m_X se aparte más del 4 % del valor teórico sea menor al 2 %. Es decir:

$$P[|m_X - \mu_x| > 0,04\mu_x] \leq 0,02$$

Si se trabaja con la expresión:

$$2 \cdot P[m_X - \mu_x < -0,04\mu_x] \leq 0,02$$

$$P\left[\left(\frac{m_X - \mu_x}{\sigma_x}\right) \cdot \sqrt{N} < -0,04 \cdot \frac{\mu_x}{\sigma_x} \cdot \sqrt{N}\right] \leq 0,01$$

La variable aleatoria $\left(\frac{m_X - \mu_x}{\sigma_x}\right) \cdot \sqrt{N}$ tiene distribución normal estándar. La llamamos Φ :

$$\Phi\left(-0,04 \cdot \frac{\mu_x}{\sigma_x} \cdot \sqrt{N}\right) \leq 0,01$$

$$\Phi\left(0,04 \cdot \frac{\mu_x}{\sigma_x} \cdot \sqrt{N}\right) \geq 0,99$$

$$0,04 \cdot \frac{\mu_x}{\sigma_x} \cdot \sqrt{N} \geq \Phi^{-1}(0,99) \approx 2,3263$$

$$N \geq 3382,3 \cdot \frac{\sigma_x^2}{\mu_x^2}$$

Para el caso analizado, $\mu_x = 3$ y $\sigma_x^2 = 1$:

$$N \geq 375,9$$

El código utilizado para verificar por simulación es el siguiente:

```

1 %% Valores de media y varianza personalizados
2 mu_x = 3;
3 var_x = 1;
4
5 %% Item E
6 %mx representa el promedio de la suma de N variables aleatorias
7 %Media: mu_x - Desviacion: sigma_x/sqrt(N)
8
9 N = 3382.3.*var_x./(mu_x.^2); %Analiticamente resulta eso y verifica
10
11 mx = makedist('Normal','mu',mu_x,'sigma',sqrt(var_x./N));
12
13 P = 2.*cdf(mx,0.96.*mu_x) %La probabilidad pedida

```

Listing 3: Código de implementación

Donde la probabilidad P calculada efectivamente resulta $\leq 0,02$.

2. Variables aleatorias conjuntamente gaussianas

En este caso se analizan dos variables aleatorias conjuntamente gaussianas, cuyos parámetros son:

Caso	μ_x	μ_y	σ_x	σ_y	ρ
A	2	3	1	1	-0.5
B	2	3	1	0.5	-0.8

Cuadro 2: Parámetros para los casos analizados

Las variables X_n con distribución normal estándar son generadas utilizando el método de simulación de monte-carlo (mediando dos variables aleatorias con distribución uniforme al igual que antes), y mediante la transformación lineal siguiente se halla la variable X :

$$X = \sigma_x X_n + \mu_x$$

Análogamente se halla la variable Y :

$$Y = \sigma_y Y_n + \mu_y$$

Para dibujar la nube de puntos con ambas variables se tiene la función de densidad de probabilidad gaussiana bivariable:

$$f_{XY}(x, y) = \frac{1}{2\pi\sigma_x\sigma_y\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)}\left[\left(\frac{x-\mu_x}{\sigma_x}\right)^2 + \left(\frac{y-\mu_y}{\sigma_y}\right)^2 - \frac{2\rho(x-\mu_x)(y-\mu_y)}{\sigma_x\sigma_y}\right]}$$

Teniendo los elementos anteriores, se implementa el siguiente código en MatLab para obtener los gráficos resultantes.

```

1 %% [2] V.A Conjuntamente Gaussianas
2 clear Workspace;
3 clc;
4
5 % Generacion de uniformes [0 , 1]
6 N = 5000;
7 X1 = rand(N,1);
8 X2 = rand(N,1);
9 X3 = rand(N,1);
10 X4 = rand(N,1);
11
12 % Generacion de gaussianas estandard
13 Y1 = sqrt(-2.*log(X1)).*cos(2.*pi.*X2);
14 Y2 = sqrt(-2.*log(X3)).*cos(2.*pi.*X4);
15
16 %% CASO A)
17 u1a = 2;
18 u2a = 3;
19 sigma1a = 1;
20 sigma2a = 1;
21 roa = -0.5;
22
23 % Gaussianas con media y varianza personalizadas
24 Z1a = sigma1a.*Y1 + u1a;
25 Z2a = sigma1a.*Y2 + u2a;
26
27 % Gaussiana bivariable
28 Z12a = (1/(2.*pi.*sigma1a.*sigma2a.*sqrt(1-roa.^2))).*exp(-(1/(2.*(1-roa.^2))).*(((Z1a-u1a)/sigma1a).^2 + ((Z2a-u2a)/sigma2a).^2 - (2.*roa.*(Z1a-u1a).*(Z2a-u2a)/(sigma1a.*sigma2a))));
29
30 figure;
31 scatter3(Z1a,Z2a,Z12a,2,'filled');
32 title('Caso A')
33 xlabel('Z1');
34 ylabel('Z2');
35 zlabel('f(Z1,Z2)');
36 set(gca,'XLim',[-4 8],'YLim',[-4 8])
37 view(-45,40)
38 print('Za','-dpng','-r600');
39
40 %% CASO B)
41 u1b = 2;

```

```

42 u2b = 3;
43 sigma1b = 1;
44 sigma2b = 0.5;
45 rob = -0.8;
46
47 %Gaussianas con media y varianza personalizadas
48 Z1b = sigma1b.*Y1 + u1b;
49 Z2b = sigma1b.*Y2 + u2b;
50
51 %Gaussiana bivariable
52 Z12b = (1/( 2.*pi.*sigma1b.*sigma2b.*sqrt(1-rob.^2) )).*exp(-( 1/(2.*(1-rob.^2)) ).*(((Z1b-u1b)/sigma1b).^2 + ((
    Z2b-u2b)/sigma2b).^2 - (2.*rob.*(Z1b-u1b).*(Z2b-u2b)/(sigma1b.*sigma2b)) ) ));
53
54 figure;
55 scatter3(Z1b,Z2b,Z12b,2,'filled');
56 title('Caso B')
57 xlabel('Z1');
58 ylabel('Z2');
59 zlabel('f(Z1,Z2)');
60 set(gca,'XLim',[-4 8],'YLim',[-4 8])
61 view(-45,40)
62 print('Zb','-dpng','-r600');

```

Listing 4: Código de implementación

Los resultados obtenidos para ambos casos se muestran a continuación.




Figura 4: Nube de puntos resultante para ambos casos

Para el caso A, se tiene que $\sigma_x = \sigma_y$, por lo que si se realizan las curvas de nivel se observarían círculos, donde la orientación de sus ejes está dada por el coeficiente de correlación ρ . En el caso B, se tiene $\sigma_x \neq \sigma_y$, por lo que las curvas de nivel resultantes son elipses. El $|\rho|$ es mayor que en el caso anterior, por lo que la orientación de sus ejes resulta distinta. Se observa que a medida que el $|\rho| \rightarrow 1$, las elipses se van 'estirando', hasta que en el límite tiende a una recta.

En dicho límite, se tiene una relación directamente lineal entre X e Y , por lo que conociendo cuánto vale uno ya se conoce el otro, mediante:

$$y = \frac{\sigma_y}{\sigma_x}x + \mu_y - \frac{\sigma_y}{\sigma_x}\mu_x$$

3. Proceso de Poisson